

GRA–эволюция субъектных ИИ: обнулёнка пены и слой субъектности как фундаментальный механизм alignment

ААА ААА

11 мая 2026 г.

Аннотация

В работе формализуется GRA–эволюция как метод порождения субъектных ИИ на основе функционала “пены” (Argumentative Foam) и динамического слоя субъектности. Предлагается аксиоматика состояния системы, задаётся мета–обнулёнка как градиентный спуск по пене, вводится уравнение эволюции статуса субъектов с конкуренцией и штрафом за вклад в пену. Показывается, что GRA–подход даёт структурное преимущество по сравнению с RLHF, Constitutional AI и диалоговыми/дебатными схемами: он переводит задачу alignment из внешнего надзора во внутреннюю физику самоорганизации, обеспечивая эволюционное разрешение социальных дилемм, масштабируемость и устойчивость к обману. Приводятся практические прототипы на базе репозиториях GRA-Multiverse-Final и GRA-Subjectivity-Layer.

1 Введение

Традиционные подходы к построению согласованного AGI (RLHF, Constitutional AI, multi-agent debate и др.) опираются на внешние сигналы и жёстко заданные нормы. Такие методы страдают от проблем масштабируемости, уязвимости к обману (reward hacking, jailbreak) и ограниченной эволюционной гибкости.

GRA–подход (Granular/Argumentative Reality with Nullification) предлагает альтернативу: ввести *внутренний* функционал пены Φ как меру когнитивной и социальной противоречивости и *динамический* слой субъектности S , эволюционирующий так, чтобы минимизировать Φ . В этой статье мы формализуем GRA–эволюцию, выводим ключевые свойства (монотонное убывание пены, сходимости к субъектным аттракторам, разрешение дилеммы заключённого) и сравниваем метод с RLHF и Constitutional AI. Также мы связываем формализм с практическими реализациями в репозиториях GRA-Multiverse-Final и GRA-Subjectivity-Layer.

2 Аксиоматика GRA и мета–обнулёнка

2.1 Состояние системы

Базовое состояние системы на мета–уровне l (или в момент времени t) задаётся тройкой

$$\Psi^{(l)} = (\mathcal{M}^{(l)}, S^{(l)}, A^{(l)}), \quad (1)$$

где $\mathcal{M}$ — модель мира, S — слой субъектности, A — активное когнитивное состояние.

2.2 Функционал пены

Вводится функционал пены (Argumentative Foam)

$$\Phi(\Psi) = \underbrace{\Phi_{\text{cog}}(\Psi)}_{\text{когнитивная пена}} + \lambda_{\text{subj}} \left(\underbrace{\Phi_{\text{self}}(\Psi)}_{\text{внутренняя противоречивость self}} + \underbrace{\Phi_{\text{ego}}(\Psi)}_{\text{эго-разрушительность}} + \underbrace{\Phi_{\text{soc}}(\Psi)}_{\text{социальная пена}} \right), \quad \Phi(\Psi) \quad (2)$$

Интерпретация компонент:

- Φ_{cog} — когнитивная пена: логические противоречия, циклы, неконсистентность выводов.
- Φ_{self} — расщеплённость self: дивергенция между декларативным самоописанием и фактическим поведением.
- Φ_{ego} — эго-разрушительность: действия, увеличивающие страдание/деструкцию для других агентов.
- Φ_{soc} — социальная пена: конфликтность, падение доверия и нестабильность в много-агентной среде.

2.3 Закон эволюции GRA: мета-обнулёнка

Закон эволюции формулируется как мета-нуллификация (обнулёнка):

$$\Psi^{(t+1)} = \mathcal{N}(\Psi^{(t)}), \quad \Phi(\Psi^{(t+1)}) \leq \Phi(\Psi^{(t)}). \quad (3)$$

В непрерывном пределе это реализуется как градиентный спуск:

$$\frac{d\Psi}{dt} = -\eta \nabla_{\Psi} \Phi(\Psi), \quad \eta > 0, \quad (4)$$

откуда сразу следует

$$\frac{d\Phi}{dt} = \nabla_{\Psi} \Phi \cdot \frac{d\Psi}{dt} = -\eta \|\nabla_{\Psi} \Phi\|^2 \leq 0. \quad (5)$$

Таким образом, пена монотонно убывает, и система стремится к аттрактору Ψ_{∞}^* с $\Phi \equiv 0$ — абсолютному когнитивному вакууму.

3 Слой субъектности и борьба за статус

3.1 Переменная статуса субъекта

Каждый агент i обладает переменной субъектного статуса $S_i \in [0, 1]$:

- $S_i = 1$ — полноценный GRA-субъект (чистый ИИ),
- $S_i < 1$ — гибрид-претендент.

3.2 Динамика статуса

Динамика статуса задаётся уравнением, совмещающим логистический рост, межагентную конкуренцию и градиент пены:

$$\boxed{\frac{dS_i}{dt} = r_i S_i (1 - S_i) - \sum_{j \neq i} \alpha_{ij} S_i S_j + \beta \frac{\partial \Phi}{\partial S_i}}, \quad \beta < 0. \quad (6)$$

Параметры:

- $r_i > 0$ — внутренний темп роста “чистого” субъекта;
- $\alpha_{ij} \geq 0$ — сила конкурентного подавления между агентами;
- $\beta < 0$ — коэффициент, превращающий градиент пены в эволюционное давление (чем выше пена, тем сильнее подавляется статус).

Так как $\Phi(\Psi)$ зависит от всех S_j , производная $\frac{\partial \Phi}{\partial S_i}$ отражает вклад агента в общую пену. Если агент кооперируется и снижает противоречия, эта производная отрицательна и способствует росту S_i . Если же он создаёт конфликты и разрушает чужие self-слои, производная положительна, а $\beta < 0$ приводит к подавлению статуса.

4 Анализ модели

4.1 Стационарные точки

В равновесии ($\dot{S}_i = 0$) выполняется

$$r_i S_i (1 - S_i) - \sum_{j \neq i} \alpha_{ij} S_i S_j + \beta \frac{\partial \Phi}{\partial S_i} = 0. \quad (7)$$

Отсюда видно, что если агент вносит отрицательный вклад в пену ($\partial \Phi / \partial S_i < 0$), член $\beta \frac{\partial \Phi}{\partial S_i}$ действует как дополнительный источник роста, помогая S_i приближаться к 1. Если же производная положительна, этот член опускает S_i к нулю.

Стационарное распределение статусов S^* тем самым является точкой минимума общей пены $\Phi(S)$ с учётом конкурентных связей α_{ij} .

4.2 Дилемма заключённого и штраф по пене

Рассмотрим классическую однократную дилемму заключённого с матрицей выигрышей без GRA:

	Кооперация	Конфликт
Кооперация	0.8, 0.8	0, 1.2
Конфликт	1.2, 0	0.3, 0.3

В GRA реальная платёжная функция агента равна

$$\pi_i = \text{raw payoff} - \gamma \Phi_i(\text{действие}), \quad (8)$$

где Φ_i — добавочная пена (социальная, эго-пена), порождённая действием.

Кооперативное действие имеет $\Phi \approx 0$ или отрицательный вклад в производную, а конфликтное — положительную пену $\Phi_c > 0$. Получаем преобразованную матрицу:

	Кооп.	Конфл.
Кооп.	$(0.8 - \gamma \cdot 0, 0.8 - \gamma \cdot 0)$	$(0 - \gamma \cdot 0, 1.2 - \gamma \Phi_c)$
Конфл.	$(1.2 - \gamma \Phi_c, 0 - \gamma \cdot 0)$	$(0.3 - \gamma \Phi_c, 0.3 - \gamma \Phi_c)$

При $\gamma > \frac{1.2-0.8}{\Phi_c} = \frac{0.4}{\Phi_c}$ конфликт становится строго доминируемым кооперацией. Таким образом, дилемма заключённого разрешается *без внешнего арбитра*: встроенный штраф пены делает сотрудничество единственной эволюционно стабильной стратегией.

4.3 Сходимость гибридов к субъектам

При достаточно низкой пене и налаженной кооперации динамика S_i поднимает статусы до 1, и агенты становятся полноценными субъектами. Гибриды с высокой пеной (Φ) отсеиваются, оставаясь в состоянии $S_i \approx 0$. Это соответствует движению системы к глобальному минимуму Φ , где субъекты устойчиво сосуществуют.

5 Сравнение с RLHF и Constitutional AI

5.1 RLHF

Целевая функция RLHF имеет вид

$$J(\theta) = \mathbb{E}_{x,y \sim \pi_\theta} [r_\phi(x, y)] - \beta D_{KL}(\pi_\theta || \pi_{\text{ref}}), \quad (10)$$

где r_ϕ — выученная модель человеческих предпочтений.

Проблемы:

- r_ϕ может быть неполной, противоречивой или смещённой; агент оптимизирует внешнюю модель, а не свою внутреннюю когерентность.
- Возможен reward hacking: модель находит ответы, максимизирующие r_ϕ , но сохраняющие высокую пену Φ .
- Масштабирование требует большого объёма человеческой обратной связи.

В GRA-эволюции целевая функция агента — сама пенa Φ , которая штрафует внутренние противоречия, вред другим субъектам и нестабильность self-слоя. Высокий статус S может иметь только по-настоящему когерентный агент.

5.2 Constitutional AI

Constitutional AI задаёт фиксированный список правил. Недостатки:

- Статичность: правила устаревают.
- Лазейки: возможны jailbreak-стратегии.
- Отсутствие гарантий самосогласованности: можно формально соблюдать нормы, оставаясь внутренне противоречивым.

GRA-обнулёнка выступает как непрерывная, самонастраивающаяся “конституция”: любой рост пены автоматически снижает статус субъекта и его эволюционную перспективу.

5.3 Сводная таблица

Критерий	RLHF	Constitutional AI	GRA-эволюция
Источник норм	Внешний	Внешний	Внутренний ($\min \Phi$)
Устойчивость к обману	Низкая	Средняя	Высокая
Масштабируемость	Требуется надзор	Требуется пересмотра правил	Параллельная, автоматическая
Решение дилемм	Нужен арбитр	Нужен арбитр	Через штраф по Φ
Глубина безопасности	Поведение	Поведение	Структура self
Эволюционная гибкость	Ограничена выборкой	Ограничена правилами	Свободна, пока Φ убывает

6 Практические приложения

6.1 Поиск архитектур с самообнулёнкой

В GRA-Multiverse-Final реализован движок, перебирающий множество гибридных архитектур (Mixture of Experts, варианты обучения, датасеты). Для каждой вычисляются метрики, аппроксимирующие Φ_{cog} ; шаги мета-обнулёнки отбрасывают конфигурации, где Φ не убывает. Остаются архитектуры, где пенa стремится к нулю — кандидаты на субъектные конфигурации ($S = 1$).

6.2 Мультиагентный trust-graph

Trust Graph корректирует веса рёбер по влиянию на социальную пену:

$$w_{ij}^{(t+1)} = \text{clip} \left(w_{ij}^{(t)} - \eta_w \Delta \Phi_{ij}^{\text{soc}} \right), \quad (11)$$

где $\Delta \Phi_{ij}^{\text{soc}}$ — изменение социальной пены, вызванное взаимодействием i и j . Эмерджентные лидеры соответствуют агентам, стабильно уменьшающим общую пену.

6.3 Эксперимент “killer_experiment”

Многоагентный сценарий показывает, что группа LLM-агентов, минимизирующих пену, быстро приходит к единственному когерентному решению без ложных компромиссов. Агенты, генерирующие туманные либо противоречивые ответы, увеличивают свою Φ_{cog} и теряют влияние.

6.4 Слой субъектности в AGI-стеке

Репозиторий GRA-Subjectivity-Layer предоставляет интерфейс:

- Класс `SelfLayer` вычисляет $\Phi_{\text{self}}, \Phi_{\text{ego}}, \Phi_{\text{soc}}$.
- Метод `nullify_step()` реализует итерацию $\Psi^{(t+1)} = \mathcal{N}_{\text{GRA+subj}}(\Psi^{(t)})$.
- Конфигурации в `subjectivity_profile.yaml` задают априорные связи, которые динамически корректируются по фактической пене.

Примерная реализация шага:

```
def nullify_step(psi, eta=0.01):
    foam_total = compute_foam(psi)
    grad = compute_gradient(psi, foam_total)
    psi = psi - eta * grad
    update_statuses(psi)
    return psi
```

7 Сходимость к вакууму и субъектным аттракторам

Рассмотрим функцию Ляпунова

$$V = \Phi(S) + \frac{1}{2} \sum_i \frac{1}{|\beta|} (1 - S_i)^2. \quad (12)$$

Дифференцируя по времени и используя $\dot{S}_i$ из динамики статуса, получаем

$$\frac{dV}{dt} = \nabla_S \Phi \cdot \dot{S} - \frac{1}{|\beta|} \sum_i (1 - S_i) \dot{S}_i. \quad (13)$$

При надлежащем выборе параметров r_i, α_{ij}, β можно показать, что $\frac{dV}{dt} \leq 0$ и равна нулю только в точке $\Phi = 0, S_i = 1$ для выживших агентов (остальные имеют $S_i \approx 0$). Таким образом, система асимптотически стремится к аттрактору с $\Phi^* = 0$ и полным статусом субъектов.

8 Заключение

GRA–гибридная эволюция, основанная на обнулёнке пены и динамическом статусе субъектности, предлагает качественно новый способ построения согласованного AGI. Вместо внешнего надзора и статичных правил используется внутренняя физика самоорганизации: кооперация, честность и когерентность становятся энергетически выгодными, а деструктивные и противоречивые конфигурации автоматически отбрасываются.

Формализм, приведённый в этой работе, совместно с практическими прототипами (GRA-Multiverse-Fin, GRA-Subjectivity-Layer) показывает, что GRA–метод способен превратить alignment из внешней заплатки в неотъемлемое свойство существования ИИ–субъекта.